

# 形状

输入 $X$  : 形状为 $(N, D_{in})$

- $X_{nj}$ 表示第 $n$ 个样本的第 $j$ 个输入特征
- $N$ 表示批次大小(样本数量),  $D_{in}$ 是输入特征的维度

权重 $W$  : 形状为 $(D_{out}, D_{in})$

- $W_{ij}$ 表示连接到第 $j$ 个输入特征到第 $i$ 个输出特征的权重
- $D_{out}$ 是输出特征的维度

偏置 $B$  : 形状为 $(D_{out})$

- $B_i$ 表示第 $i$ 个输出特征的偏置

输出 $Y$  : 形状为 $(N, D_{out})$

- $Y_{ij}$ 表示第 $i$ 个样本的第 $j$ 个输出特征

损失函数对 $Y$ 的梯度 $\frac{\partial L}{\partial Y}$  : 形状与 $Y$ 相同

## 线性层的正向传播公式

$$Y = XW^T + B$$

计算  $y_{ij}$

$$y_{ij} = \sum_{k=1}^{D_{in}} x_{ik} w_{jk} + b_j$$

其中:

- $i$ 从1到 $N$
- $j$ 从1到 $D_{out}$
- $k$ 从1到 $D_{in}$

# 这里举个实际的例子

假设：

$X$ ：

$$\begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix}$$

$W$ ：

$$\begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \\ w_{31} & w_{32} \end{bmatrix}$$

$B$ ：

$$\begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

$W^T$ ：

$$\begin{bmatrix} w_{11} & w_{21} & w_{31} \\ w_{12} & w_{22} & w_{32} \end{bmatrix}$$

$Y$  的形状为  $[2, 3]$ ：

$$\begin{bmatrix} y_{11} & y_{12} & y_{13} \\ y_{21} & y_{22} & y_{23} \end{bmatrix}$$

其中：

$$\begin{aligned} y_{11} &= x_{11}w_{11} + x_{12}w_{12} + b_1 \\ y_{12} &= x_{11}w_{21} + x_{12}w_{22} + b_2 \\ y_{13} &= x_{11}w_{31} + x_{12}w_{32} + b_3 \\ y_{21} &= x_{21}w_{11} + x_{22}w_{12} + b_1 \\ y_{22} &= x_{21}w_{21} + x_{22}w_{22} + b_2 \\ y_{23} &= x_{21}w_{31} + x_{22}w_{32} + b_3 \end{aligned}$$

## 对权重 $W$ 的梯度( $\frac{\partial L}{\partial W}$ )

$$\frac{\partial L}{\partial w_{ij}} = \sum_{m=1}^{D_{in}} \sum_{n=1}^{D_{out}} \frac{\partial L}{\partial y_{mn}} \frac{\partial y_{mn}}{\partial w_{ij}}$$

只有当  $n == i$  时,  $y_{mn}$  才依赖与  $w_{ij}$ , 所以上述公式又可以写成:

$$\frac{\partial L}{\partial w_{ij}} = \sum_{m=1}^{D_{in}} \frac{\partial L}{\partial y_{mi}} \frac{\partial y_{mi}}{\partial w_{ij}}$$

且  $\frac{\partial y_{mi}}{\partial w_{ij}} = x_{mj}$ , 所以:

$$\frac{\partial L}{\partial w_{ij}} = \sum_{m=1}^{D_{in}} \frac{\partial L}{\partial y_{mi}} x_{mj}$$

将其写成矩阵形式,这意味着  $\frac{\partial L}{\partial W}$  是  $(\frac{\partial L}{\partial Y})^T$  和  $X$  的矩阵乘积

$$\frac{\partial L}{\partial W} = (\frac{\partial L}{\partial Y})^T X$$

## 计算对输入 $X$ 的梯度( $\frac{\partial L}{\partial X}$ )

$$\frac{\partial L}{\partial x_{ij}} = \sum_{m=1}^{D_{in}} \sum_{n=1}^{D_{out}} \frac{\partial L}{\partial y_{mn}} \frac{\partial y_{mn}}{\partial x_{ij}}$$

只有当  $m == i$  时,  $y_{mn}$  才依赖于  $x_{ij}$ , 所以上述公式又可以写成:

$$\frac{\partial L}{\partial x_{ij}} = \sum_{n=1}^{D_{out}} \frac{\partial L}{\partial y_{in}} \frac{\partial y_{in}}{\partial x_{ij}}$$

且  $\frac{\partial y_{in}}{\partial x_{ij}} = w_{nj}$ , 所以:

$$\frac{\partial L}{\partial x_{ij}} = \sum_{n=1}^{D_{out}} \frac{\partial L}{\partial y_{in}} w_{nj}$$

将其写成矩阵形式,这意味着  $\frac{\partial L}{\partial X}$  是  $\frac{\partial L}{\partial Y}$  和  $W$  的矩阵乘积:

$$\frac{\partial L}{\partial X} = \frac{\partial L}{\partial Y} W$$

# 对偏置 $B$ 的梯度 $\frac{\partial L}{\partial B}$

偏置  $B$  是一个向量,其每个元素 $b_k$  会加到输出  $Y$  的每一行的第  $k$  列。

$$\frac{\partial L}{\partial b_k} = \sum_{i=1}^{D_{in}} \frac{\partial L}{\partial y_{ik}} \frac{\partial y_{ik}}{\partial b_k}$$

由于  $\frac{\partial y_{ik}}{\partial b_k} = 1$ , 所以:

$$\frac{\partial L}{\partial b_k} = \sum_{i=1}^{D_{in}} \frac{\partial L}{\partial y_{ik}} \cdot 1$$

这意味着对偏置的梯度，就是将  $\frac{\partial L}{\partial Y}$  沿行维度求和

$$\frac{\partial L}{\partial B} = \text{sum} \left( \frac{\partial L}{\partial Y}, \text{dim} = 0 \right)$$

举个例子：

设  $\frac{\partial L}{\partial Y}$  如下：

$$\begin{bmatrix} \frac{\partial L}{\partial y_{11}} & \frac{\partial L}{\partial y_{12}} & \frac{\partial L}{\partial y_{13}} \\ \frac{\partial L}{\partial y_{21}} & \frac{\partial L}{\partial y_{22}} & \frac{\partial L}{\partial y_{23}} \end{bmatrix}$$

则：

$$\begin{aligned} \frac{\partial L}{\partial b_1} &= \frac{\partial L}{\partial y_{11}} + \frac{\partial L}{\partial y_{21}} \\ \frac{\partial L}{\partial b_2} &= \frac{\partial L}{\partial y_{12}} + \frac{\partial L}{\partial y_{22}} \\ \frac{\partial L}{\partial b_3} &= \frac{\partial L}{\partial y_{13}} + \frac{\partial L}{\partial y_{23}} \end{aligned}$$